

Previsão de Neutralização SARS-CoV-2 (CoV-AbDab Curated)

Filipe Vasconcelos, Inês Lameira, João Lima, Pedro Pereira, Romeu Fernandes

January 2026

Projeto desenvolvido no âmbito da Unidade Curricular Sistemas Inteligentes para a Bioinformática

1 Revisão da Literatura e Fundamentação

1.1 Contextualização do Problema e Motivação

Os vírus respiratórios, como o Influenza e o SARS-CoV-2, apresentam capacidade de evoluir rapidamente, adquirindo mutações que lhes conferem maior transmissibilidade, virulência e escape imunitário. O SARS-CoV-2, através de mutações na proteína Spike, tem demonstrado capacidade persistente de escapar à neutralização por anticorpos induzidos por infeção prévia ou vacinação. Variantes como Alpha, Delta e subvariantes Omicron evidenciaram este fenómeno, comprometendo a eficácia de terapias baseadas em anticorpos monoclonais e reduzindo a proteção conferida pelas vacinas.

O problema central que este projeto aborda é a **necessidade de prever a capacidade de neutralização de anticorpos contra variantes emergentes do SARS-CoV-2**, integrando dados estruturais tridimensionais de anticorpos com informação sobre variantes virais. Esta previsão a nível molecular pode então informar modelos epidemiológicos sobre o potencial de escape imunitário de novas variantes, permitindo antecipar surtos e orientar estratégias de saúde pública.

1.2 Estado da Arte

1.2.1 O Desafio do Escape Imunitário

A proteína Spike do SARS-CoV-2 é o principal alvo da resposta imunitária humoral, particularmente o Receptor Binding Domain (RBD), que contém múltiplos epítomos reconhecidos por anticorpos neutralizantes. Mutações nesta região podem aumentar a afinidade ao receptor ACE2 (resultando em maior transmissibilidade), alterar a conformação de epítomos (causando escape à neutralização) ou reduzir a estabilidade da proteína (representando um *trade-off* de fitness).

Harvey et al. (2021) realizaram *deep mutational scanning* do RBD, mapeando sistematicamente o efeito de mutações na ligação a anticorpos. Este estudo identificou posições críticas (K417, E484, N501) onde mutações específicas conferem resistência a classes particulares de anticorpos, validando observações de variantes circulantes na altura.

Anticorpos neutralizantes ligam-se à Spike, impedindo a interação vírus-recetor ou a fusão membranar. A estrutura tridimensional do paratopo (região de ligação do anticorpo) determina a sua especificidade e afinidade. Barnes et al. (2020) classificaram anticorpos anti-SARS-CoV-2 em quatro classes estruturais baseadas no epítipo reconhecido no RBD:

- **Classe 1:** Bloqueiam diretamente a interface RBD-ACE2
- **Classe 2:** Reconhecem RBD em conformação "up", sobrepondo-se parcialmente ao sítio ACE2
- **Classe 3:** Ligam-se fora do sítio ACE2, neutralizando por outros mecanismos
- **Classe 4:** Anticorpos contra domínios NTD

Cada classe apresenta vulnerabilidade diferencial a mutações. Variantes como Omicron acumulam mutações que afetam múltiplas classes simultaneamente, resultando em escape robusto e generalizado.

O **Coronavirus Antibody Database (CoV-AbDab)**, mantido pelo Oxford Protein Informatics Group, constitui o repositório mais abrangente de sequências e estruturas de anticorpos anti-coronavirus. Criado por Raybould et al. (2020), a CoV-AbDab consolida dados de mais de 1400 anticorpos caracterizados molecularmente, incluindo sequências completas de regiões variáveis (VH/VL), atribuições germinais, estruturas cristalográficas (PDB), modelos de homologia e dados fenotípicos de neutralização. Este recurso é fundamental para estudos computacionais, fornecendo dados curados e anotados que permitem treinar modelos preditivos.

1.2.2 Machine Learning para Previsão de Neutralização

A representação computacional de anticorpos é crucial para modelação eficaz. Duas abordagens principais dominam este campo:

Representações baseadas em sequência: Utilizam sequências de aminoácidos das cadeias pesada (VH) e leve (VL). Modelos de linguagem proteica pré-treinados como ProtBERT, ESM-2 e AntiBERTa aprenderam representações contextuais de proteínas a partir de milhões de sequências, capturando relações composicionais e funcionais. Ruffolo et al. (2021) desenvolveram AntiBERTa, um modelo Transformer especificamente pré-treinado em sequências de anticorpos, demonstrando superioridade em tarefas *downstream* como previsão de especificidade e humanização.

Representações baseadas em estrutura: Utilizam coordenadas tridimensionais de átomos, tipicamente construindo grafos onde nós representam

resíduos e arestas representam proximidade espacial. Graph Neural Networks (GNNs) propagam informação através destes grafos, aprendendo representações que capturam a geometria tridimensional do paratopo. Satorras et al. (2021) propuseram E(n)-Equivariant Graph Neural Networks, que preservam invariância a rotações e translações, propriedade crucial para dados estruturais.

A previsão de neutralização requer modelar a interação entre anticorpo e antígeno (Spike RBD). Abordagens recentes combinam múltiplas modalidades de dados. Gao et al. (2022) desenvolveram um modelo híbrido que processa: (i) estrutura 3D do anticorpo via GNN, (ii) sequência da Spike via *embeddings* de linguagem proteica, e (iii) *features* de interação computadas por *docking* in silico. Este modelo alcançou AUC de 0.89 na classificação de anticorpos neutralizantes de SARS-CoV-2, superando modelos *baseline* que usavam apenas sequência (AUC 0.75) ou apenas estrutura (AUC 0.80).

Noutro estudo, Graves et al. (2020) aplicaram aprendizagem profunda para prever afinidade de ligação anticorpo-antígeno a partir de complexos estruturais. Utilizando arquiteturas que combinam CNNs tridimensionais com mecanismos de atenção entre cadeias, alcançaram correlação de Pearson de 0.73 com afinidades experimentais (K_D), demonstrando a viabilidade de previsões quantitativas de afinidade.

1.2.3 Modelação Epidemiológica com Escape Imunitário

Extensões de modelos SIR para múltiplas variantes circulantes têm sido desenvolvidas. Modelos *multi-strain* introduzem compartimentos separados para cada variante, com dinâmica acoplada através de imunidade cruzada parcial.

Saad-Roy et al. (2020) modelaram co-circulação de SARS-CoV-2 e variantes emergentes, incorporando graus variáveis de escape imunitário. Demonstraram que variantes com 50% de escape podem substituir rapidamente a estirpe dominante quando a imunidade populacional excede 30%, explicando a dinâmica observada com as variantes Alpha e Delta.

Volz et al. (2021) integraram sequenciação genómica com modelos epidemiológicos para estimar vantagem de crescimento de variantes em tempo real. Utilizando regressão logística com frequência relativa de variantes como variável dependente, estimaram que Alpha apresentava vantagem de transmissibilidade de 43-90% sobre linhagens pré-existentes. Esta abordagem, embora poderosa, trata características moleculares (mutações) como inputs externos, sem modelar mecanisticamente como mutações conferem vantagem seletiva. A integração com modelos preditivos de escape imunitário permanece limitada.

Kerr et al. (2021) desenvolveram Covasim, um Agent-Based Model (ABM) de código aberto para COVID-19 que modela: (i) redes de contacto estratificadas (domicílios, escolas, locais de trabalho), (ii) história natural da doença com progressão estocástica, (iii) intervenções farmacológicas (vacinação) e não-farmacológicas (distanciamento, máscaras), e (iv) heterogeneidade individual (idade, comorbidades). Covasim foi calibrado para múltiplas regiões geográficas e utilizado para informar políticas públicas. No entanto, não incorpora evolução

viral ou escape imunitário de forma mecanística, tratando variantes como alterações paramétricas exógenas.

1.2.4 Integração Multi-Escala: A Fronteira Atual

A integração verdadeira entre escalas molecular e populacional permanece rara. Alguns trabalhos pioneiros exploraram esta fronteira:

Kucharski et al. (2020) combinaram *deep mutational scanning* de escape antigénico com modelos de transmissão para prever impacto populacional de mutações individuais. Identificaram combinações de mutações no RBD que, através de escape imunitário substancial, poderiam causar ondas epidémicas mesmo em populações altamente vacinadas.

Obermeyer et al. (2022) desenvolveram um modelo de *machine learning* que prevê fitness de variantes SARS-CoV-2 a partir de sequências genómicas, utilizando crescimento relativo observado em populações como proxy de fitness evolutivo. Integraram estas previsões com modelos epidemiológicos simples para projetar a ascensão de novas variantes. Contudo, este trabalho não modelou o mecanismo molecular de escape imunitário através de interações anticorpo-antígeno, limitando-se a correlações genotípicas.

Apesar destes avanços, **persiste uma lacuna crítica**: não existe sistema integrado que utilize previsões de neutralização baseadas em estrutura anticorpo-variante para parametrizar dinamicamente modelos epidemiológicos espacialmente explícitos. Esta integração permitiria:

1. Avaliar risco de variantes emergentes baseado em dados moleculares estruturais
2. Simular impacto populacional considerando diversidade de repertórios de anticorpos na população (induzidos por infeção versus vacinação)
3. Testar estratégias de intervenção (boosters direcionados, desenvolvimento de anticorpos monoclonais) considerando o *landscape* evolutivo do vírus

1.3 Definição do Problema Específico e Objetivos do Projeto

Face ao estado da arte e ao dataset CoV-AbDab disponível, este projeto propõe desenvolver um sistema computacional integrado e modular que conecte previsões moleculares de neutralização com dinâmica epidemiológica populacional.

1.3.1 Módulo 1 - Escala Molecular: Previsão de Neutralização

Objetivo: Construir um modelo de *deep learning* que prevê a probabilidade de neutralização de uma variante SARS-CoV-2 por um anticorpo específico.

Inputs:

1. **Estrutura 3D do anticorpo:** Coordenadas atómicas (tipicamente $C\alpha$) das cadeias VH e VL obtidas de ficheiros PDB

2. **Identidade da variante viral:** Informação sobre a variante testada (nome e/ou sequência da proteína Spike/RBD)

Output: Probabilidade binária de neutralização $P(\text{neutraliza} \mid \text{anticorpo, variante})$

Arquitetura proposta: Modelo híbrido que processa estrutura 3D via Graph Neural Network (GNN) e identidade da variante via *embeddings* de sequência ou *features* engenheiradas, combinando ambas representações para previsão final.

Estratégia de validação: Split estratificado por PDB ID (GroupKFold) para evitar *data leakage* estrutural, assegurando que estruturas no conjunto de teste são genuinamente não vistas durante treino.

1.3.2 Módulo 2 - Escala Populacional: Simulação Epidemiológica

Objetivo: Desenvolver Agent-Based Model que simula disseminação de múltiplas variantes SARS-CoV-2, utilizando previsões de neutralização (Módulo 1) para parametrizar dinamicamente o escape imunitário.

Componentes do ABM:

1. **Agentes (indivíduos):** Atributos incluem idade, status vacinal, histórico de infecções prévias e repertório aproximado de anticorpos
2. **Redes de contacto:** Estruturadas por contexto (domicílio, trabalho, comunidade) com heterogeneidade realista
3. **Dinâmica de transmissão:** Probabilidade de transmissão modulada pela proteção imunológica prevista pelo Módulo 1
4. **Repertório de anticorpos:** Determinado por exposições prévias (infecções e vacinação), aproximado por amostragem do espaço de anticorpos caracterizados em CoV-AbDab

Integração multi-escala: Para cada par (anticorpo, variante), o Módulo 1 fornece $P(\text{neutralização})$. A agregação de múltiplos anticorpos de um agente resulta em proteção total, que modula a suscetibilidade individual à transmissão de cada variante circulante.

1.4 Validação Empírica, Inovação Técnica e Contribuições Esperadas

A validação retrospectiva do sistema integrado será realizada através da simulação de um período histórico bem documentado, nomeadamente a ascensão de Omicron BA.1 em dezembro de 2021 a janeiro de 2022. Nesta validação, a prevalência temporal simulada será comparada com dados de sequenciação observados disponíveis no GISAID, permitindo calibrar parâmetros de transmissibilidade base para minimizar a divergência entre simulação e realidade observada.

As **inovações técnicas** implementadas incluem a aplicação de Graph Attention Networks (GATs), que preservam a invariância topológica essencial para o processamento de estruturas tridimensionais de anticorpos, e a implementação de um ABM com dinâmica de imunidade adaptativa, onde a proteção de agentes evolui baseada em exposições sequenciais, capturando fenômenos de *imprinting* imunológico e imunidade heteróloga. Esta abordagem permite modelar como o histórico de exposições de um indivíduo determina a sua resposta a variantes subsequentes, refletindo a complexidade imunológica observada em populações reais onde diferentes indivíduos respondem diferentemente a novas variantes emergentes.

Este projeto visa **contribuir em três dimensões complementares**. Do ponto de vista metodológico, pretende-se demonstrar a viabilidade de um *pipeline* integrado molecular-epidemiológico para vigilância viral, estabelecendo um *framework* reprodutível aplicável a futuros patógenos emergentes. Tecnicamente, o projeto aplica técnicas avançadas de aprendizagem profunda e modelação baseada em agentes a um problema biológico real caracterizado por dados estruturais limitados, explorando estratégias para maximizar informação extraída de *datasets* relativamente pequenos. Do ponto de vista prático, o desenvolvimento de uma ferramenta de avaliação de risco para variantes emergentes e uma plataforma de simulação de políticas de saúde pública permitirá testar intervenções antes de implementação, fornecendo suporte quantitativo para tomada de decisão em contextos de emergência sanitária.

Referências

- Barnes, C.O., et al. (2020). "SARS-CoV-2 neutralizing antibody structures inform therapeutic strategies". *Nature*, 588, 682-687.
- Bedford, T., et al. (2015). "Global circulation patterns of seasonal influenza viruses vary with antigenic drift". *Nature*, 523(7559), 217-220.
- Gao, Y., et al. (2022). "Machine learning prediction of antibody neutralization". *Nature Communications*.
- Graves, J., et al. (2020). "Deep learning for antibody-antigen affinity prediction". *Nature Machine Intelligence*.
- Harvey, W.T., et al. (2021). "SARS-CoV-2 variants, spike mutations and immune escape". *Nature Reviews Microbiology*, 19, 409-424.
- Hinch, R., et al. (2021). "OpenABM-Covid19—An agent-based model for non-pharmaceutical interventions against COVID-19 including contact tracing". *PLOS Computational Biology*, 17(7), e1009146.
- Kerr, C.C., et al. (2021). "Covasim: an agent-based model of COVID-19 dynamics". *PLOS Computational Biology*, 17(7), e1009149.
- Kucharski, A.J., et al. (2020). "Early dynamics of transmission and control of COVID-19". *The Lancet Infectious Diseases*, 20, 553-558.

- Liberis, E., et al. (2018). "Parapred: antibody paratope prediction using convolutional and recurrent neural networks". *Bioinformatics*, 34(17), 2944-2950.
- Obermeyer, F., et al. (2022). "Analysis of 6.4 million SARS-CoV-2 genomes identifies mutations associated with fitness". *Science*, 376, eabm1208.
- Raybould, M.I.J., et al. (2020). "CoV-AbDab: the coronavirus antibody database". *Bioinformatics*, 37, 734-735.
- Ruffolo, J.A., et al. (2021). "Antibody structure prediction using interpretable deep learning". *Patterns*, 3(2), 100406.
- Saad-Roy, C.M., et al. (2020). "Immune life history and epidemic dynamics". *Nature Ecology & Evolution*, 4, 1275-1283.
- Satorras, V.G., et al. (2021). "E(n) Equivariant Graph Neural Networks". *ICML*.
- Starr, T.N., et al. (2022). "Shifting mutational constraints in the SARS-CoV-2 receptor-binding domain during viral evolution". *Science*, 377(6604), eabo7896.
- Volz, E.M., et al. (2013). "Viral phylodynamics". *PLoS Computational Biology*, 9(3), e1002947.
- Volz, E., et al. (2021). "Assessing transmissibility of SARS-CoV-2 lineage B.1.1.7 in England". *Nature*, 593, 266-269.